



**Universidad Nacional
del Altiplano**

Escuela Profesional de
Ingeniería de Sistemas

Curso: Análisis de Datos

Análisis Exploratorio de Datos de Denuncias Policiales (SIDPOL) 2018–2025

**Identificación de Patrones Delictivos Regionales
mediante Técnicas de Análisis de Datos**

Autores:

Aracayo Mamani, Jhon Marco
Canaza Paucara, Juan Diego

Docente: Ing. Jimenez Chura, Adolfo Carlos

Semestre: IX | 2025-II

Contexto: La Seguridad Ciudadana como Prioridad Nacional

La seguridad ciudadana es una de las principales preocupaciones en el Perú. El gran volumen de información del Sistema de Denuncias Policiales (SIDPOL) es clave para entenderla, pero representa un desafío analítico significativo.



Problema Complejo

La dinámica delictiva requiere un análisis basado en evidencia para la toma de decisiones estratégicas y efectivas.



Oportunidad en Datos Abiertos

SIDPOL ofrece una fuente invaluable de hechos reportados por la ciudadanía para analizar el delito en tiempo y espacio.



Desafío del Volumen

El gran volumen de registros dificulta la extracción de patrones relevantes sin aplicar un análisis sistemático y avanzado.

Insight Clave: El Análisis Exploratorio de Datos (EDA) es el puente entre el dato crudo y la inteligencia accionable para diseñar políticas públicas más efectivas.

Problema y Hoja de Ruta Analítica

Problema Principal: Las denuncias policiales varían significativamente por tiempo, geografía y modalidad. Sin un análisis sistemático, es imposible identificar patrones clave para optimizar la asignación de recursos y las estrategias de prevención.

Objetivo General: Realizar un Análisis Exploratorio de Datos para identificar patrones temporales, geográficos y por modalidad delictiva, y agrupar departamentos según su perfil criminalístico.



Analizar:

Identificar las modalidades y departamentos con mayor concentración de denuncias y analizar su distribución estadística.



Procesar:

Evaluar la calidad de los datos, tratar valores atípicos mediante transformaciones y preparar el dataset para el modelado.



Modelar:

Aplicar PCA y K-Means para reducir la dimensionalidad e identificar clústeres de regiones con perfiles delictivos similares.

El Activo Principal: Dataset de Denuncias Policiales (SIDPOL)

El análisis se basa en el conjunto de datos de Denuncias Policiales, proveniente de la Plataforma Nacional de Datos Abiertos del Perú.

Descripción

- **Fuente:** Plataforma Nacional de Datos Abiertos (datosabiertos.gob.pe)
- **Periodo de Estudio:** Enero 2018 – Diciembre 2025
- **Naturaleza del Registro:** Cada fila representa un conteo agregado de denuncias para una combinación única de fecha, ubicación y modalidad delictiva.



340,767

Registros Agregados



8

Variables Analizadas

Insight Clave:

Al ser un dataset agregado, cada valor alto en la variable "CANTIDAD" no es una anomalía, sino una concentración real y significativa de eventos delictivos.

Anatomía de los Datos: Variables del Estudio

Ocho variables estructuran el dataset, combinando dimensiones temporales, geográficas y categóricas para describir cada registro de denuncia.

Variable	Tipo	Descripción
`ANIO`, `MES`	Cuantitativa Discreta	Componentes temporales del registro.
`DPTO_HECHO_NEW`	Cualitativa Nominal	Departamento donde ocurrió el hecho.
`PROV_HECHO`	Cualitativa Nominal	Provincia donde ocurrió el hecho.
`DIST_HECHO`	Cualitativa Nominal	Distrito donde ocurrió el hecho.
`UBIGEO_HECHO`	Cualitativa Nominal	Código de ubicación geográfica estándar.
`P_MODALIDADES`	Cualitativa Nominal	Tipo de delito o modalidad reportada.
`CANTIDAD`	Cuantitativa Discreta	Variable Objetivo: Conteo de denuncias.

Variable Clave: `CANTIDAD`

Esta variable es el foco de nuestro análisis, ya que mide la magnitud del fenómeno delictivo en cada registro agregado.

Fundamentos Sólidos: Verificación de Calidad de Datos

Un análisis robusto comienza con datos de alta calidad. El dataset SIDPOL demuestra una integridad excepcional, eliminando la necesidad de imputación o depuración.

Resultados del Diagnóstico

- ✓ **0% de Datos Faltantes:** Todas las columnas están 100% completas. Se verificó que no hay valores nulos en ninguna de las 8 variables.
- ✓ **0 Registros Duplicados:** No existen registros idénticos bajo la clave agregada (fecha, lugar, modalidad), garantizando la unicidad de cada entrada.

Resumen Visual

Compleitud del Dataset

0%

Valores Faltantes: Valores Faltantes

Unicidad de Registros

0

Registros Duplicados: Registros Duplicados

Insight Clave: La alta calidad de los datos nos permite proceder directamente al análisis exploratorio con un alto grado de confianza en la fiabilidad de los hallazgos.

Primera Mirada: Estadística Descriptiva de `CANTIDAD`

Los estadísticos básicos de la variable `CANTIDAD` revelan una historia de alta dispersión y una fuerte concentración en valores bajos.

Media

19.85

El promedio de denuncias por registro agregado.

Mediana

3

El 50% de los registros tiene 3 o menos denuncias.

Desviación Estándar

57.21

Indica una altísima dispersión de los datos alrededor de la media.

Máximo

1,302

El registro con la mayor concentración de denuncias.

Interpretación:

La gran diferencia entre la media (19.85) y la mediana (3) es un claro indicador de una distribución fuertemente asimétrica a la derecha.

Insight Clave:


El fenómeno delictivo no es homogéneo. La mayoría de las combinaciones (lugar/fecha/modalidad) tienen pocas denuncias, pero existen eventos extremos que elevan drásticamente el promedio y son de alto impacto.



Forma de la Distribución: Concentración y Valores Extremos


La visualización de la variable `CANTIDAD` confirma la asimetría positiva y la presencia de valores extremos significativos que representan concentraciones reales del delito.

Histograma de Frecuencia de `CANTIDAD`



Interpretación: La distribución está masivamente sesgada a la derecha (asimetría positiva). La frecuencia de conteos bajos es abrumadoramente alta.

Diagrama de Caja de `CANTIDAD`



Interpretación: La caja intercuartílica está compactada en la base, mientras que los puntos superiores son valores extremos reales.




Insight Clave: Estos "valores atípicos" no son errores; representan "puntos calientes" de criminalidad real y de alto impacto que demandan la mayor atención en el análisis y en la política pública.

Análisis Univariado: ¿Qué Delitos Predominan a Nivel Nacional?

El análisis de las modalidades revela los tipos de delitos más frecuentemente denunciados en el Perú, destacando la violencia de género y los delitos patrimoniales.

Top 15 Modalidades Delictivas por Suma de Denuncias (2018-2025)



Interpretación:

La categoría "Otros" agrupa un gran volumen, pero la violencia contra la mujer, el hurto y el robo constituyen los delitos específicos más reportados y definidos.



Insight Clave:

La violencia de género y los delitos contra el patrimonio (hurto y robo) representan el núcleo de la problemática de seguridad ciudadana reportada en el sistema SIDPOL.

Análisis Univariado: ¿Dónde se Concentra el Delito?

La dimensión geográfica muestra una fuerte concentración de las denuncias en las áreas urbanas más pobladas del país, con Lima Metropolitana como el principal foco de incidencia.

Top 15 Departamentos por Suma de Denuncias (2018-2025)




Interpretación: Lima Metropolitana acumula una cantidad de denuncias que supera con creces la suma de los siguientes departamentos en el ranking.

Insight Clave: La densidad poblacional y la centralización económica de la capital la convierten en el epicentro absoluto de la criminalidad reportada, requiriendo estrategias de seguridad con una escala y enfoque diferenciados.

Análisis Univariado: ¿Cómo Varía el Delito en el Tiempo?

La serie temporal de denuncias totales revela tendencias, estacionalidad y el impacto de eventos externos, como la pandemia, demostrando la naturaleza dinámica del fenómeno.

Evolución Mensual de Denuncias Totales (2018-2025)



Interpretación:

La serie muestra una tendencia general al alza con fluctuaciones estacionales. Se observa una caída abrupta y significativa a inicios de 2020, coincidente con las medidas de confinamiento.




Insight Clave:

Inter Regular. El delito no es estático; responde a factores sociales y eventos coyunturales de gran escala. Esto subraya la necesidad de un monitoreo constante y adaptable.

Análisis Bivariado: El "Rostro" del Delito por Región

La distribución de modalidades delictivas no es uniforme en el país. Cada región tiene un perfil criminalístico particular, revelando distintas realidades socioterritoriales.

Distribución Porcentual de Modalidades por Departamento (Top 10)




Interpretación: Se observan perfiles distintos. Por ejemplo, en departamentos urbanos como Lima, los delitos patrimoniales (Hurto, Robo) tienen un peso proporcional mayor, mientras que en otras regiones predominan delitos de otra naturaleza.

Insight Clave: No se puede aplicar una estrategia de seguridad única para todo el Perú. El análisis socioterritorial es fundamental para diseñar intervenciones focalizadas y efectivas.

Preparación de Datos: Gestión de Asimetría para Modelado

Para preparar los datos para algoritmos sensibles a la escala, se aborda la asimetría extrema de 'CANTIDAD' mediante una transformación logarítmica, que estabiliza la varianza sin perder información.


Distribución Original



Distribución Original (Asimetría Extrema)



Distribución Transformada



Distribución Transformada (Varianza Estabilizada)


Justificación Técnica:

Se aplica $\log(1 + \text{CANTIDAD})$ en lugar de eliminar outliers. Esto preserva la información de los "puntos calientes" pero reduce su influencia desproporcionada, mejorando el rendimiento de algoritmos como PCA y K-Means.

Modelado: Segmentación de Regiones por Perfil Delictivo


Aplicando PCA para reducir la dimensionalidad y K-Means para agrupar, revelamos la estructura subyacente de los datos: clústeres de departamentos con "firmas" delictivas similares.

PCA - Reducción de Dimensión



Interpretación: Los dos primeros componentes principales capturan más del 99% de la varianza total, permitiendo una representación fiel del perfil delictivo en un plano 2D.

K-Means - Clustering



Interpretación de Clústeres:

- * Clúster 1 (Cyan): Outlier de alto impacto y perfil único (Lima Metropolitana).
- * Clúster 0 (Azul): Regiones con perfiles diversos y volumen intermedio-alto.
- * Clúster 2 (Verde): Regiones con menor concentración general de denuncias.



Insight Clave: El análisis revela "arquetipos" de criminalidad regional. Existen grupos de departamentos con perfiles similares que podrían beneficiarse de estrategias de seguridad coordinadas o análogas.

Conclusiones: De los Datos a la Estrategia

El Análisis Exploratorio de Datos ha transformado un masivo conjunto de registros en una visión estructurada y accionable de la seguridad ciudadana en el Perú.



CONCENTRACIÓN

El delito está fuertemente concentrado en áreas urbanas (Lima) y en modalidades específicas como violencia de género y delitos patrimoniales.



HETEROGENEIDAD

No existe un 'delito peruano' único. Cada región posee un perfil delictivo distintivo, como demuestran los clústeres, que requiere soluciones a medida.



DINAMISMO

El fenómeno delictivo es dinámico y sensible a factores externos. El monitoreo continuo es crucial para una respuesta ágil y proactiva.

Mensaje Final: Este análisis sienta las bases para desarrollar modelos predictivos y diseñar políticas públicas de seguridad ciudadana más inteligentes, eficientes y, sobre todo, basadas en evidencia.