

UNIVERSIDAD NACIONAL DEL ALTIPLANO
FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA, ELECTRÓNICA
Y SISTEMAS
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



CURSO:

ANALISIS DE DATOS

TEMA:

TRABAJO DE DATOS ABIERTOS

DOCENTE:

ING. JIMENEZ CHURA, Adolfo Carlos

PRESENTADO POR:

ARACAYO MAMANI, Jhon Marco

CANAZA PAUCARA, Juan Diego

SEMESTRE: IX

CICLO: 2025- II

PUNO – PERÚ

2025

Indice

TRABAJO DE DATOS ABIERTOS	3
1. Introducción	3
2. Definición del problema y objetivos de negocio	3
2.1 Problema de la naturaleza	3
2.2 Objetivo general	4
2.3 Objetivos específicos	4
3. Descripción del dataset	4
4. Evaluación de la completitud de la información	6
5. Análisis estadístico descriptivo	6
5.1 Medidas de tendencia central y dispersión	6
5.2 Forma de la distribución	7
6. Resumen global univariado	8
6.1 Modalidades delictivas predominantes	8
6.2 Departamentos con mayor número de denuncias	9
6.3 Evolución temporal	10
7. Análisis de asociación	11
8. Análisis de valores atípicos	12
9. Análisis de Componentes Principales (PCA)	13
10. Agrupamiento mediante K-Means	14
11. Factores principales que explican el problema	15
12. Conclusiones	16

TRABAJO DE DATOS ABIERTOS

1. Introducción

La seguridad ciudadana constituye una de las principales preocupaciones sociales en el Perú. Las denuncias policiales registradas en el Sistema de Denuncias Policiales (SIDPOL) reflejan los hechos delictivos reportados por la ciudadanía y permiten analizar la dinámica del delito en el tiempo y el espacio.

Sin embargo, el gran volumen de información disponible dificulta la identificación de patrones relevantes si no se aplica un análisis sistemático. En este contexto, el Análisis Exploratorio de Datos (EDA) se convierte en una herramienta fundamental para comprender la distribución, concentración y comportamiento de las denuncias policiales, así como para apoyar la toma de decisiones en materia de seguridad ciudadana.

El presente trabajo realiza un EDA sobre el dataset de denuncias policiales SIDPOL correspondiente al periodo 2018–2025, complementado con técnicas de reducción de dimensionalidad (PCA) y agrupamiento (K-Means), con el objetivo de identificar patrones delictivos regionales.

2. Definición del problema y objetivos de negocio

2.1 Problema de la naturaleza

Las denuncias policiales presentan variaciones significativas según el tiempo, la ubicación geográfica y el tipo de delito. Sin un análisis adecuado, resulta difícil identificar zonas críticas,

modalidades predominantes y diferencias regionales que permitan priorizar recursos y diseñar estrategias de prevención eficaces.

2.2 Objetivo general

Realizar un Análisis Exploratorio de Datos del dataset SIDPOL para identificar patrones temporales, geográficos y por modalidad delictiva, así como agrupar departamentos según su perfil delictivo.

2.3 Objetivos específicos

- Analizar la distribución estadística de las denuncias policiales.
- Identificar las modalidades delictivas y departamentos con mayor concentración de denuncias.
- Evaluar la completitud y calidad de la información.
- Analizar asociaciones entre modalidades delictivas y regiones.
- Detectar valores atípicos y justificar su tratamiento.
- Aplicar PCA y K-Means para identificar grupos de departamentos con perfiles delictivos similares.

3. Descripción del dataset

El dataset utilizado corresponde a datos abiertos del Perú:

Denuncias policiales (SIDPOL) 2018–2025

Fuente: Datos Abiertos Perú

Cada registro representa un **conteo agregado** de denuncias para una combinación específica de:

- Año
- Mes
- Ubicación geográfica
- Modalidad delictiva


3.1 Variables del estudio

Variable	Tipo
ANIO	Cuantitativa discreta
MES	Cuantitativa discreta ordinal
DPTO_HECHO_NEW	Cualitativa nominal
PROV_HECHO	Cualitativa nominal
DIST_HECHO	Cualitativa nominal
UBIGEO_HECHO	Cualitativa nominal
P_MODALIDADES	Cualitativa nominal
CANTIDAD	Cuantitativa discreta (conteo agregado)

4. Evaluación de la completitud de la información

El análisis de completitud evidenció que el dataset cuenta con **340,767 registros y 8 variables**, sin valores faltantes en ninguna columna (0 % de datos nulos). Asimismo, no se identificaron registros duplicados bajo la clave agregada.

Por tanto, no fue necesario aplicar métodos correctivos de imputación o depuración de datos.



	A	B	C	D	E	F	G	H
1	columna,missing_%,missing_n							
2	ANIO,0.0,0							
3	MES,0.0,0							
4	DPTO_HECHO_NEW,0.0,0							
5	PROV_HECHO,0.0,0							
6	DIST_HECHO,0.0,0							
7	UBIGEO_HECHO,0.0,0							
8	P_MODALIDADES,0.0,0							
9	CANTIDAD,0.0,0							
10								
11								

Tabla de valores faltantes por variable

(archivo: 01_missing_por_columna.csv)

5. Análisis estadístico descriptivo

5.1 Medidas de tendencia central y dispersión

La variable principal **CANTIDAD** presenta los siguientes estadísticos:

- Media: 19.85
- Mediana: 3
- Desviación estándar: 57.21
- Máximo: 1302



Estos valores indican una fuerte concentración de registros con bajos conteos y pocos registros con valores elevados.

5.2 Forma de la distribución

La distribución presenta:

- Alta asimetría positiva
- Curtosis elevada

Esto evidencia la existencia de valores extremos asociados a concentraciones reales del delito.



- Histograma de la variable CANTIDAD
(03_hist_cantidad)
- Boxplot de CANTIDAD
(04_boxplot_cantidad)

6. Resumen global univariado

6.1 Modalidades delictivas predominantes

Las modalidades con mayor número de denuncias son:

- Otros

- Violencia contra la mujer e integrantes
- Hurto
- Robo




Gráfico de barras horizontales – Top 15 modalidades

(06_barh_top15_modalidades)

6.2 Departamentos con mayor número de denuncias

Lima Metropolitana presenta la mayor concentración de denuncias, seguida por Arequipa, Lambayeque y La Libertad.




Gráfico de barras – Top 15 departamentos

(08_barh_top15_departamentos.)

6.3 Evolución temporal

La serie temporal muestra variaciones mensuales y anuales, evidenciando que el fenómeno delictivo no es constante en el tiempo.




Gráfico de línea – Denuncias

totales por mes

(10_linea_tendencia_global.png)

7. Análisis de asociación

Se analizó la relación entre modalidad delictiva y departamento mediante tablas normalizadas y gráficos apilados. Los resultados muestran que la distribución de modalidades varía significativamente entre regiones.

Por ejemplo, en departamentos amazónicos predominan delitos relacionados con violencia familiar, mientras que en regiones urbanas se observa mayor presencia de delitos patrimoniales como hurto y robo.






Gráfico de barras apiladas – Modalidades por departamento

(11_modalidades_apiladas_top10_dptos.png)

8. Análisis de valores atípicos

Mediante el método del rango intercuartílico (IQR) se identificaron valores atípicos en la variable CANTIDAD. Sin embargo, al tratarse de un dataset agregado, estos valores representan concentraciones reales del delito, principalmente en zonas urbanas densamente pobladas.

En lugar de eliminar registros, se aplicó una transformación logarítmica $\log(1 + \text{CANTIDAD})$ para reducir la asimetría y estabilizar la varianza.



Histograma original de CANTIDAD

- Histograma logarítmico de CANTIDAD_LOG

9. Análisis de Componentes Principales (PCA)

Se construyó una matriz numérica agregada por departamento y modalidad delictiva, la cual fue estandarizada. El PCA mostró que:

- El primer componente explica aproximadamente el 97 % de la varianza.
- Los dos primeros componentes explican más del 99 % de la varianza total.

Esto permitió reducir la dimensionalidad sin pérdida significativa de información.




Gráfico de varianza explicada acumulada del PCA

10. Agrupamiento mediante K-Means

Utilizando los dos primeros componentes principales, se aplicó el algoritmo K-Means. El método del codo indicó que **k = 3 clusters** es una elección adecuada.

Los clusters identificados agrupan departamentos con perfiles delictivos similares, diferenciando claramente:

- Regiones altamente urbanizadas
- Regiones con actividad delictiva intermedia

- Regiones con menor concentración de denuncias




Gráfico PCA + K-Means con clusters de departamentos

11. Factores principales que explican el problema

A partir del análisis realizado, se identifican como factores clave:

- La concentración urbana y densidad poblacional
- El tipo de modalidad delictiva
- La dimensión temporal
- La heterogeneidad regional

Estos factores explican las diferencias observadas en la distribución de las denuncias policiales a nivel nacional.

12. Conclusiones

El Análisis Exploratorio de Datos permitió comprender la estructura y comportamiento de las denuncias policiales en el Perú. Los resultados evidencian una fuerte concentración del delito en determinadas regiones y modalidades, así como patrones diferenciados entre departamentos.

El uso de PCA y K-Means permitió identificar grupos de departamentos con perfiles delictivos similares, proporcionando información valiosa para el diseño de estrategias de seguridad ciudadana focalizadas.